

УКРАЇНСЬКИЙ КАТОЛИЦЬКИЙ УНІВЕРСИТЕТ

КУРС «ШТУЧНИЙ ІНТЕЛЕКТ» · СЕМЕСТРОВИЙ ПРОЄКТ · 2026

AI vs Original music Classification

Дослідження акустичних «відбитків» AI-генераторів музики для ідентифікації джерела згенерованого аудіо та його відмінностей від реальної музики.

Команда:

БОДНАР АЛІНА
ВІТЧИНКІНА СОФІЯ
ДОВБЕНЧУК ОЛЕНА

Ментор:

ОМЕЛЬЧУК ОЛЕСЯ

Репозиторій:

[https://github.com/Olenadovb/
AI-vs-Original-Music-Classification](https://github.com/Olenadovb/AI-vs-Original-Music-Classification)

*Пропозиція проєкту, подана в межах курсу
«Штучний інтелект»*

Факультет прикладних наук



2026-09-21

1. Проблема та мотивація

Основна проблема, на вирішення якої спрямований наш проєкт – це прозорість походження музики. Ми досліджуємо, чи залишають різні моделі генерації музики характерні акустичні «відбитки», за якими можна визначити не лише те, чи є аудіо AI-згенерованим, а й яким саме генератором воно було створене. Це дозволяє перейти від простого розрізнення AI-generated vs real до аналізу відмінностей між генеративними моделями та ідентифікації конкретного джерела аудіо.

2. Огляд джерел та наявних рішень

Автори FakeMusicCaps дослідили attribution музики, згенерованої різними text-to-music моделями. Для відомих генераторів вони отримали високі результати, однак open-set експеримент із невідомим Suno показав значно гіршу здатність до узагальнення [1]. Це дослідження є основним стартовим етапом для нашого проєкту. Ідея характерних «відбитків» генеративних систем також досліджувалася для synthetic speech: у роботі про Audio Deepfake Attribution порівнювали handcrafted features і pretrained embeddings та показали можливість ідентифікації конкретного генератора й виявлення невідомих систем [2]. Інше дослідження на FakeMusicCaps порівнює різні архітектури, out-of-domain evaluation та XAI і показує, що високі результати всередині одного датасету не завжди добре узагальнюються на інші дані [3]. Спираючись на ці результати, ми зосередимося на аналізі акустичних ознак і pretrained embeddings як можливих fingerprints окремих music generators та перевіримо їх у closed- і open-set сценаріях.

3. Дані

Основним набором даних буде FakeMusicCaps [1], який містить близько 27 тисяч 10-секундних аудіофрагментів, згенерованих різними text-to-music моделями на основі описів із MusicCaps. Датасет буде використано для дослідження відмінностей між генераторами та побудови closed-set класифікації. Додатково розглядається AIME [4], доступний через Hugging Face, що містить 6000 AI-generated треків від 12 моделей і сервісів та 500 реальних треків MTG-Jamendo. Для порівняння з реальною музикою планується використати MusicCaps [5], доступний через Hugging Face, і SunoCaps [6], доступний на Kaggle, – для open-set експерименту з генератором, відсутнім в основних навчальних даних.

Основні набори даних є відкритими та доступними для дослідницького використання. AIME поширює 6000 згенерованих треків за ліцензією CC BY 4.0; MTG-Jamendo мають окремі ліцензії для кожного треку, а використані description tags – CC BY-NC-SA 4.0. MusicCaps має ліцензію CC BY-SA 4.0 так само як SunoCaps. FakeMusicCaps відкрито доступний через Zenodo; автори вимагають цитувати супровідну роботу, однак окрему ліцензію для набору аудіоданих у metadata поточної версії Zenodo не зазначено.

4. Підхід і методи

Основний підхід полягатиме у пошуку акустичних «відбитків», характерних для різних text-to-music генераторів. Для кожного аудіофрагмента планується отримати handcrafted acoustic features, що описують спектральні, темпоральні, ритмічні та тональні властивості сигналу, а також embeddings із pretrained audio-моделей. Подібне поєднання handcrafted features та pretrained representations уже використовувалося в задачах audio source attribution [2]. Спочатку буде проведено статистичний аналіз ознак та досліджено структуру feature і embedding spaces за допомогою PCA та UMAP. Clustering буде використано для перевірки, чи формуються природні групи, що відповідають окремим генераторам. Також буде перевірено, наскільки ці закономірності зберігаються для різних музичних описів і наборів даних. Для перевірки того, наскільки знайдені характеристики дозволяють ідентифікувати джерело аудіо, будуть використані прості класифікаційні моделі, зокрема SVM, Logistic Regression та k-NN. Експерименти проводитимуться як у closed-set сценарії для відомих генераторів, так і в open-set

сценарії з генератором.

5. Оцінювання результатів

Для closed-set задачі ідентифікації генератора основними метриками будуть macro F1-score, balanced accuracy, precision та recall. Додатково використовуватиметься confusion matrix, щоб побачити, які генератори модель найчастіше плутає між собою. Подібні метрики використовуються для оцінювання якості ідентифікації генераторів у FakeMusicCaps [1].

Для задачі AI-generated vs real music використовуватимуться ті самі метрики. В open-set експерименті окремо перевірятиметься, чи може система розпізнати аудіо від генератора, якого вона не бачила під час навчання; для цього аналізуватимуться F1-score та recall для невідомого генератора разом із якістю класифікації відомих. Це важливо, оскільки попередні дослідження показують, що моделі можуть добре працювати з відомими генераторами, але значно гірше з новими [1, 2].

Як baseline планується використати SVM на embeddings, отриманих готовою pretrained audio-моделлю без її додаткового навчання. Його результати порівнюватимуться з k-NN, Logistic Regression та класифікацією на handcrafted acoustic features. Там, де експериментальна постановка збігатиметься, результати також буде зіставлено з baseline результатами, наведеними авторами FakeMusicCaps.

6. План і ризики

До мідтерму планується підготувати FakeMusicCaps до експериментів, проаналізувати його структуру та metadata, отримати handcrafted acoustic features і pretrained audio embeddings та провести їх первинний аналіз. Також буде реалізовано базову closed-set класифікацію для визначення генератора.

Після мідтерму планується провести повне порівняння різних representations і класифікаторів, додати експеримент AI-generated vs real та open-set сценарій з генератором, якого не було в навчальних даних. На завершальному етапі результати буде узагальнено та проаналізовано, які характеристики аудіо найбільш корисні для визначення його походження.

Основними ризиками є те, що модель може добре працювати на відомих генераторах, але гірше узагальнюватися на нові [1, 3]. У такому випадку буде окремо проаналізовано, які representations є найбільш стійкими до зміни генератора та де виникає падіння якості. Також різні датасети можуть відрізнятися не лише походженням музики, а й форматом або якістю аудіо, через що модель може навчитися розпізнавати саме ці відмінності замість характеристик генератора. Для зменшення цього впливу аудіо буде приведено до однакового формату. Ще один ризик - це випадкове потрапляння дуже схожих прикладів у train і test, що може завищити результати. Щоб цього уникнути, розбиття даних контролюватиметься за prompts, щоб дуже схожі приклади, створені з одного опису, не потрапляли одночасно в обидві частини.

7. Contribution statement

- Боднар Аліна — підготовка даних, preprocessing, handcrafted acoustic features, EDA
- Вітчинкіна Софія — pretrained audio embeddings, PCA/UMAP, clustering, аналіз representations
- Довбенчук Олена — baseline-моделі, closed- та open-set експерименти, evaluation

Список джерел

- [1] Luca Comanducci, Paolo Bestagini, and Stefano Tubaro. Fakemusiccaps: A dataset for detection and attribution of synthetic music generated via text-to-music models. *arXiv preprint arXiv:2409.10684*, 2024. URL: <https://arxiv.org/abs/2409.10684>.
- [2] Xinrui Yan, Jiangyan Yi, Jianhua Tao, and Jie Chen. Audio deepfake attribution: An initial dataset and investigation. *arXiv preprint arXiv:2208.10489*, 2022. URL: <https://arxiv.org/abs/2208.10489>.
- [3] Yupei Li, Qiyang Sun, Hanqian Li, Lucia Specia, and Björn W. Schuller. Explainable detection of machine generated music and early systematic evaluation. *Scientific Reports*, 16:13757, 2026. doi:10.1038/s41598-026-42133-7.
- [4] Ahmet Solak, Florian Grötschla, Luca A. Lanzendörfer, and Roger Wattenhofer. Benchmarking music generation models and metrics via human preference studies. In *2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 1–5. IEEE, 2025. URL: <https://huggingface.co/datasets/disco-eth/AIME>, doi:10.1109/ICASSP49660.2025.10887745.
- [5] Andrea Agostinelli, Timo I. Denk, Zalán Borsos, Jesse Engel, Mauro Verzetti, Antoine Caillon, Qingqing Huang, Aren Jansen, Adam Roberts, Marco Tagliasacchi, Matt Sharifi, Neil Zeghidour, and Christian Frank. Musiclm: Generating music from text, 2023. MusicCaps dataset, licensed under CC BY-SA 4.0. URL: <https://huggingface.co/datasets/google/MusicCaps>, arXiv:2301.11325, doi:10.48550/arXiv.2301.11325.
- [6] Miguel Civit, Véronique Drai-Zerbib, David Lizcano, and María José Escalona. Sunocaps: A novel dataset of text-prompt based ai-generated music with emotion annotations. *Data in Brief*, 55:110743, 2024. URL: <https://www.kaggle.com/datasets/migueltcivit/sunocaps>, doi:10.1016/j.dib.2024.110743.